

LAPORAN PROYEK AKHIR

Preprocessing & Unsupervised Learning (Clustering)

Dataset: Mall Customer Segmentation Algoritma: K-Means Clustering

Bahasa: Python 3 (scikit-learn, pandas, matplotlib)

NAMA : DITIA WULANDARI

NIM : 241011401219

1. PENDAHULUAN

Proyek ini bertujuan untuk mengimplementasikan teknik Unsupervised Learning pada data pelanggan mall. Dengan memanfaatkan algoritma K-Means Clustering, diharapkan dapat ditemukan segmentasi pelanggan berdasarkan usia, pendapatan, dan perilaku belanja, tanpa label yang diberikan secara eksplisit.

Hasil segmentasi ini dapat dimanfaatkan oleh tim pemasaran untuk merancang strategi promosi yang lebih tepat sasaran sesuai dengan karakteristik setiap kelompok pelanggan.

1.1 Deskripsi Dataset

Dataset yang digunakan adalah simulasi data **Mall Customer** yang terinspirasi dari dataset publik di Kaggle. Dataset ini memiliki 530 baris (sebelum cleaning) dan 5 kolom, yaitu:

Kolom	Tipe	Deskripsi
CustomerID	Integer	ID unik pelanggan
Gender	Kategorik	Jenis kelamin (Male/Female) – tidak konsisten
Age	Numerik	Usia pelanggan (tahun)
Annual_Income_k	Numerik	Pendapatan tahunan (ribuan USD)
Spending_Score	Numerik	Skor belanja 1-100 dari mall

Kecacatan data yang ditemukan:

- Missing values: 57 Gender, 26 Age, 26 Annual_Income_k, 30 Spending_Score
- Duplikat: 30 baris identik

- Format tidak konsisten: Gender menggunakan 7 variasi (Male, male, M, Female, female, F, None)

2. TAHAP CLEANING DATA

2.1 Penghapusan Duplikat

Sebanyak 30 baris duplikat ditemukan dan dihapus menggunakan fungsi `df.drop_duplicates()`.

Jumlah data berkurang dari 530 menjadi 500 baris.

```
df = df.drop_duplicates()
```

2.2 Standardisasi Nilai Gender

Kolom Gender memiliki 7 variasi nilai yang tidak konsisten. Dibuat fungsi mapping untuk menyeragamkan semua variasi menjadi hanya dua nilai: **Male** dan **Female**.

3.2 Standardisasi Nilai Gender

```
def clean_gender(val):  
    if pd.isna(val):  
        return np.nan  
    v = str(val).strip().lower()  
    if v in ['male', 'm']:  
        return 'Male'  
    elif v in ['female', 'f']:  
        return 'Female'  
    return np.nan  
  
df['Gender'] = df['Gender'].apply(clean_gender)  
print(f"Distribusi Gender: {df['Gender'].value_counts().to_dict()}")
```

Distribusi Gender: {'Male': 228, 'Female': 224}

3.3 Imputasi Missing Values

Missing values pada kolom numerik (Age, Annual_Income_k, Spending_Score) diisi menggunakan nilai median karena lebih robust terhadap outlier dibandingkan mean. Kolom Gender diisi menggunakan modus.

3.3 Imputasi Missing Values

```
# Imputasi numerik dengan median
df['Age'] = df['Age'].fillna(df['Age'].median())
df['Annual_Income_k'] = df['Annual_Income_k'].fillna(df['Annual_Income_k'].median())
df['Spending_Score'] = df['Spending_Score'].fillna(df['Spending_Score'].median())

# Imputasi Gender dengan modus
df['Gender'] = df['Gender'].fillna(df['Gender'].mode()[0])

print(f"Missing values setelah imputasi: {df.isnull().sum().sum()}")
df.describe()
```

Encoding dan Feature Scaling

Kolom Gender di-encode secara numerik (Male=0, Female=1). Tiga fitur utama (Age, Annual_Income_k, Spending_Score) dinormalisasi menggunakan **StandardScaler** agar setiap fitur memiliki skala yang setara (mean=0, std=1), mencegah fitur dengan skala besar mendominasi perhitungan jarak.


```
# StandardScaler
scaler = StandardScaler()
X_scaled = scaler.fit_transform(X)
```

3. IMPLEMENTASI K-MEANS CLUSTERING

3.1 Penentuan Jumlah Cluster Optimal

Dua metode digunakan untuk menentukan nilai K optimal:

- **Metode Elbow:** Mengidentifikasi titik "siku" pada kurva inertia (WCSS) terhadap nilai K. Penurunan inertia yang signifikan berhenti di sekitar K=5-6.
- **Silhouette Score:** Mengukur seberapa baik setiap objek terklasifikasi ke klusternya. Nilai maksimum diperoleh pada K=6 (score=0.2779).





3.2 Fitting K-Means

K-Means dijalankan dengan K=6, inisialisasi k-means++ (via `n_init=10`), dan `random_state=42` untuk reproduktifitas.

```
kmeans = KMeans(n_clusters=best_k, random_state=42, n_init=10)
df['cluster'] = kmeans.fit_predict(X_scaled)
```

4. VISUALISASI HASIL CLUSTERING





5. EVALUASI DAN INTERPRESTASI CLUSTER

5.1 Metrik Evaluasi

Silhouette Score = 0.2779 pada K=6. Nilai ini menunjukkan bahwa cluster cukup terpisah satu sama lain. Nilai mendekati 1.0 sempurna, sementara nilai >0.25 pada data real-world 3D dianggap dapat diterima.

5.1 Profil dan Label Cluster

Cluster	Usia	Pendapatan	Skor Belanja	Label Segmen
0	~55 thn	Rendah (~48k)	Tinggi (~70)	Konsumen Setia Hemat
1	~40 thn	Tinggi (~109k)	Tinggi (~79)	Konsumen Premium
2	~58 thn	Tinggi (~108k)	Rendah (~37)	Kaya tapi Selektif
3	~52 thn	Rendah (~49k)	Rendah (~19)	Konsumen Pasif
4	~33 thn	Tinggi (~98k)	Rendah (~25)	Potensi Belum Terkonversi
5	~26 thn	Rendah (~47k)	Sedang (~55)	Konsumen Muda Aktif

6. KESIMPULAN

Proyek ini berhasil menyelesaikan seluruh tahapan dari preprocessing hingga clustering dan evaluasi:

- Data mentah (530 baris, 5 kolom) berhasil dibersihkan: 30 duplikat dihapus, missing values diimputasi, dan format Gender distandardisasi.
- K-Means dengan K=6 dipilih berdasarkan Silhouette Score tertinggi (0.2779) dan pola Elbow yang terlihat pada K=5-6.
- Enam segmen pelanggan berhasil diidentifikasi dengan karakteristik unik yang dapat digunakan sebagai dasar strategi pemasaran bertarget.
- Visualisasi 2D (scatter plot dan PCA) menunjukkan pemisahan cluster yang dapat diinterpretasikan secara bisnis.